端侧通用决策与模型调用方案

Jev 决策模块负责选择，程序负责调用，大模型负责困难问题；通用初版完成后，再做领域验证。

平台接入：DeepSeek Harness 等（需开发适配） ｜ 决策与调用接口独立，便于接入其他智能体框架

1 可替换的模型与工具

本地决策模型候选（负责选择）

AnyJev + Qwen3-0.6B / 1.7B
或 Tacit-1.7B（独立开放决策模型）
用途：比较候选，输出选择与分数

端侧小语言模型候选（负责处理）

Qwen3-0.6B / 1.7B
DeepSeek-R1-Distill-Qwen-1.5B
Gemma-3-1B-IT / SmolLM2-1.7B-Instruct
Phi-3.5-mini-Instruct
用途：文本处理、参数提取与短回复

专用模型候选

文字识别：PP-OCRv5（PaddleOCR）
图像检测：YOLO11n / YOLOv8n
文本检索：bge-small-zh-v1.5

远端大模型候选（LLM 兜底）

DeepSeek API（Flash / Pro）
Qwen3-14B / 32B、Gemma-3-12B-IT
其他兼容 API 的大模型服务
用途：复杂推理、重规划与异常恢复

常规程序工具

计算 / 查询 / 文件操作
按明确规则执行，返回可检查的结果

能力清单：能做什么、参数格式、运行位置

资源登记：内存、耗时、网络与调用开销

按设备和实测筛选，不要求全部部署。

清单

2 核心：怎样选择与升级

① 程序筛掉不能用的候选

检查权限、设备资源、网络与预算
形成可用候选；没有可用办法则停止并说明

② Jev 决策模块决定交给谁

输入：处理要求 + 可用候选 + 已有结果

比较候选能力，选择合适的一个

小语言模型 | 专用模型 | 程序工具 | 远端 LLM | 停止

输出：候选编号 + 各选项概率 / 判断分数

③ 程序检查：执行、重新选择或升级

结合判断分数、结果检查与剩余资源
满足条件 → 准备参数并调用
不确定 / 结果不合格 → 重选或请求大模型
断网 / 预算不足 → 本地降级或停止

本地实现与商用 Jev 分开验证

端侧主线：本地开放模型承担决策
联网对照：商用 Jev API（远端服务）
AnyJev / Tacit 不等同于商用 Jev

分数不是正确率；升级阈值需用样本验证。
规则检查能否调用，决策模型比较谁更合适。

调用

3 程序怎样调用与验证

按编号找到调用接口

查登记清单：接口、参数格式、运行位置
Jev 给出选择，程序发起实际调用

准备参数，再做检查

初版：固定模板；必要时由小模型提取
检查类型、必填项、范围与权限
远端调用还需检查网络和剩余额度
参数不合格：补充信息、重选或停止

执行，并记录过程

本地：运行小模型、专用模型或工具
远端：请求大模型，带回结果或新计划
新计划仍要检查参数与执行条件
统一返回：结果、错误、耗时与开销

验证结果，再决定下一步

调用成功 ≠ 处理正确；按预设条件检查
结果合格：返回结果或继续下一步
结果不合格：有限重试，反馈决策模块
请求大模型仍可能失败，必要时停止
记录选择、失败原因与远端调用次数

平台负责运行，核心模块独立

DeepSeek Harness 等：管理工具与流程
需实现决策适配和各模型调用接口
限制时间与重试次数，避免反复循环
更换平台或模型后，重新检查兼容性

反馈结果与失败原因，更新状态后再次选择

定本地决策实现
选定后端，明确与执行模型的分工

→

定选择与升级条件
区分硬性规则、模型判断与结果检查

→

接通调用与反馈
明确参数、结果、超时和失败处理

→

做出可运行初版
少量候选跑通，再检查质量与开销

之后用遥感或养老任务验证并迭代：决策是否正确、升级是否及时，以及完整流程的质量、延迟与成本。